مشروع حرائق الغابات — مراجعة المشروع 4

بناء وتقييم نماذج تعلم الآلة لتصنيف حالات بدء الحرائق

الهدف: عرض نهاية المشروع (End-to-End) ومقارنة النماذج.

النطاق: بيانات كاليفورنيا اليومية (1984–2023).

الجلسة: Milestone 4

التاريخ: 30 أكتوبر 2026

المشكلة والبيانات المستخدمة

هدف المشروع

تصنيف الأيام بناءً على احتمالية تسجيل "بدء حريق" (Fire Start) باستخدام ملاحظات الطقس اليومية.

بعد تنبيه المهندس حول صغر حجم البيانات السابقة (244 سجلًا)، تم الانتقال إلى **California Weather and Fire Prediction Dataset**.

المصدر يدمج بيانات الطقس من NOAA (الإدارة الوطنية للمحيطات والغلاف الجوي) مع سجلات حوادث الحرائق من CAL FIRE.

** ملاحظة: هذا تصنيف تاريخي لليوم نفسه، وليس نظام تنبؤ استباقي مؤكد.*

14,988

إجمالي السجلات اليومية

2025 – 1984

فترة التغطية الزمنية

فحص الجودة وقرار التغطية

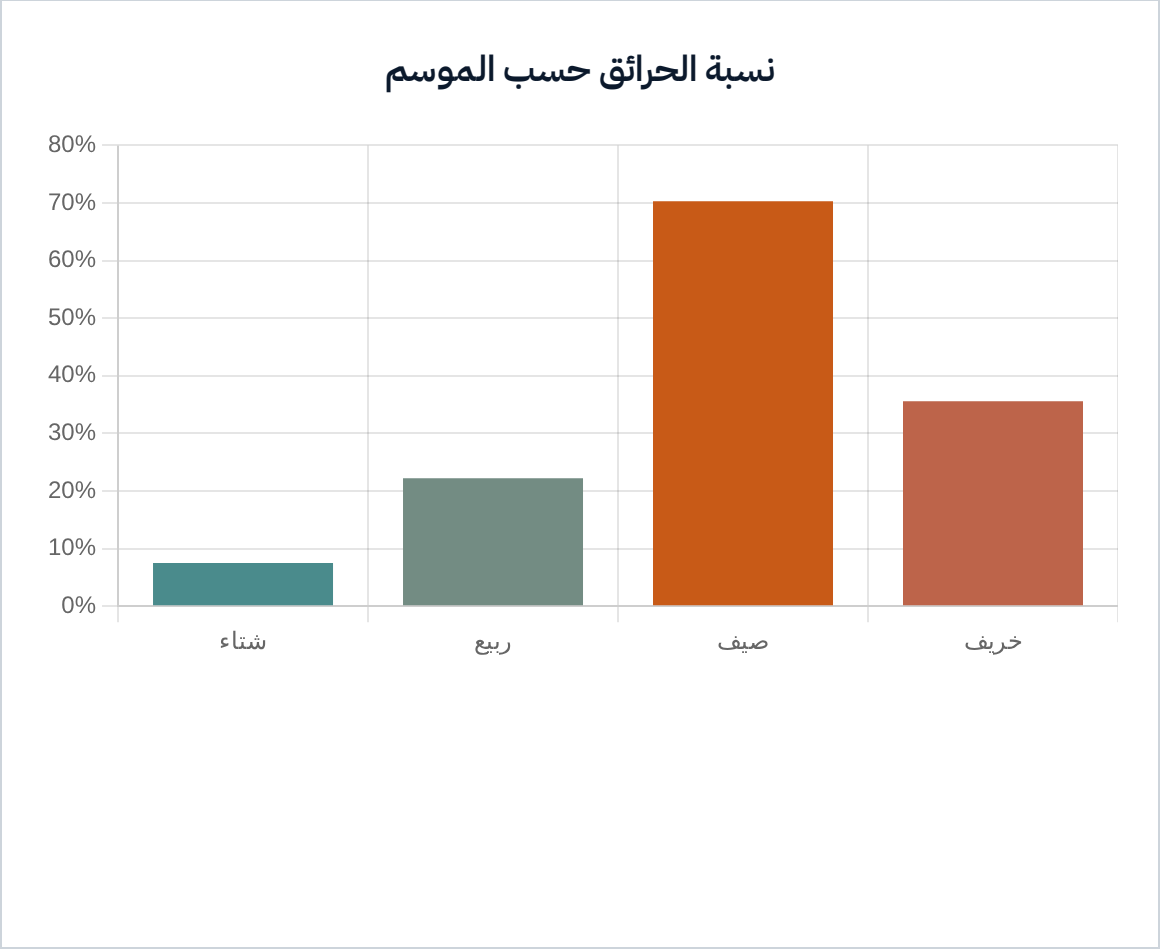
المؤشر	القيمة
إجمالي الصفوف الخام	14,988
الصفوف المكررة	0
قيم الرياح الناقصة	3
الصفوف المستبعدة (2024-2025)	378
إجمالي عينة التحليل والنمذجة	14,610

قرار استبعاد 2024 – 2025

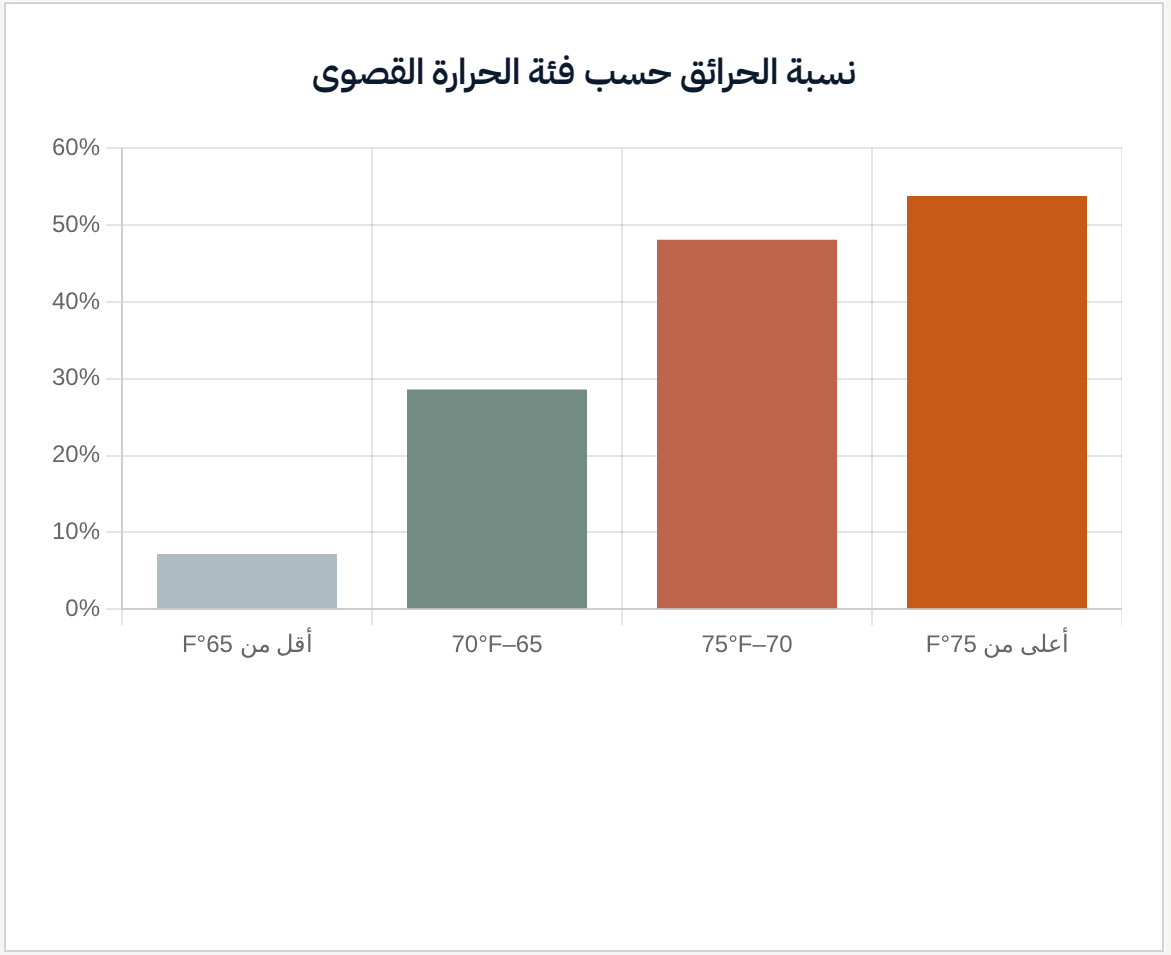
أظهر التدقيق أن جميع أيام سنة 2024 وبداية 2025 مسجلة كحالات "عدم بدء حريق" (False)، وهو ما يخالف النمط التاريخي.

لتجنب تلوث النموذج ببيانات قد تكون غير مكتملة الوسوم، تقرر حصر العمل على الفترة الموثقة **1984 – 2023**.

ماذا لاحظنا في البيانات؟

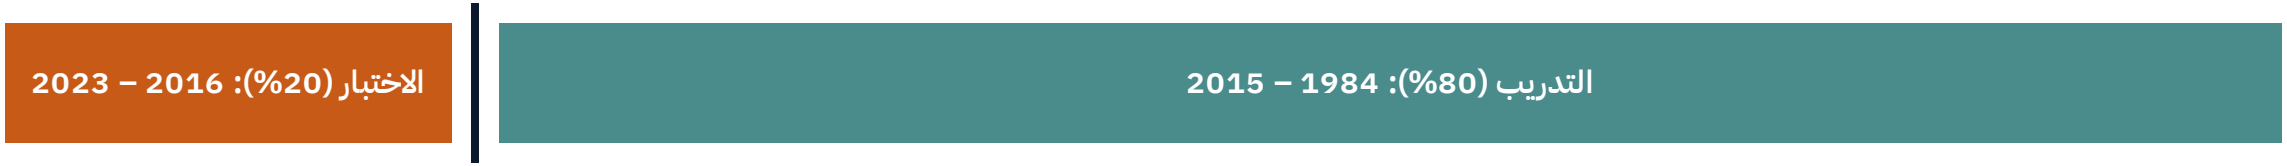


تركز واضح للحرائق في فصل **الصيف (70.3%)** مقارنة بالشتاء (7.5%). الموسم يعمل كـ "بديل" (Proxy) لمجموعة ظروف جوية وبشرية معقدة.



ارتباط طردي مع الحرارة: الأيام التي تزيد حرارتها عن **F°75** سجلت حرائق بنسبة 53.8%، بينما انخفضت إلى 7.2% للأيام الأبرد من F°65.

التجهيز والتقسيم الزمني



هندسة الخصائص المصححة

تم إعادة بناء ميزات الطقس للأيام السبعة السابقة (Lagged Features) من الصفوف الماضية فقط، لضمان عدم وجود تسرب لبيانات اليوم الحالي داخل الميزات المتوقعة.

منع تسرب البيانات (No Leakage)

تم حساب قيم الإحلال (Imputation) والتحجيم (Scaling) والترميز (Encoding) بناءً على بيانات التدريب فقط، ثم تطبيقها على بيانات الاختبار لضمان نزاهة التقييم.

النماذج المختارة ولماذا؟

Logistic Regression

نموذج خطي بسيط وسريع التفسير. يعمل جيدًا كخط أساس متطور وبناء احتمالات متزنة بين الفئات (Balanced Class Weights).

Random Forest

خوارزمية تجميعية (Ensemble) قوية في التعامل مع العلاقات غير الخطية والتفاعلات بين ميزات الطقس، مع تقليل خطر الإفراط في التخصيص.

Histogram Gradient Boosting

تطوير حديث لتقنية تعزيز التدرج، فعال جدًا مع مجموعات البيانات الكبيرة والمتنوعة ويتعامل بكفاءة مع القيم العددية الواسعة.

مقياس الاختيار الأساسي: Average Precision (AP). اخترنا هذا المقياس لأنه يلخص العلاقة بين الدقة والاستدعاء (Precision/Recall) عبر عتبات مختلفة، وهو أكثر تعبيرًا في حالات البيانات غير المتوازنة زمنيًا.

مقارنة النماذج عبر تحقق زمني

متوسط خمس طيات متتابعة على بيانات التدريب فقط | القيم المعروضة: Average Precision وBalanced Accuracy وF1

النموذج	Average Precision	Balanced Accuracy	F1
Logistic Regression	0.652 ± 0.102	0.742	0.646
Random Forest	0.648 ± 0.113	0.755	0.660
Histogram Gradient Boosting	0.623 ± 0.126	0.698	0.577
Majority baseline	0.321 ± 0.071	0.500	0.000

الاختيار: Logistic Regression فاز بفارق صغير في متوسط Average Precision عن Random Forest، لذلك نستخدمه كتوازن بين الأداء والتركيب الأبسط. التحقق المتقاطع استُخدم للاختيار، ومتوسط الفائز ليس تقديرًا غير متحيزًا للأداء بسبب عملية الاختيار.

نتيجة الاختبار النهائي

نموذج Logistic Regression | فترة الاختبار: 2016–2023 (2,922 يومًا) | عتبة ثابتة 0.5

71.7%	72.8%
Accuracy	Balanced Accuracy
64.2%	87.0%
Precision لحالات الحريق	Recall لحالات الحريق
73.8%	0.797
F1	Average Precision

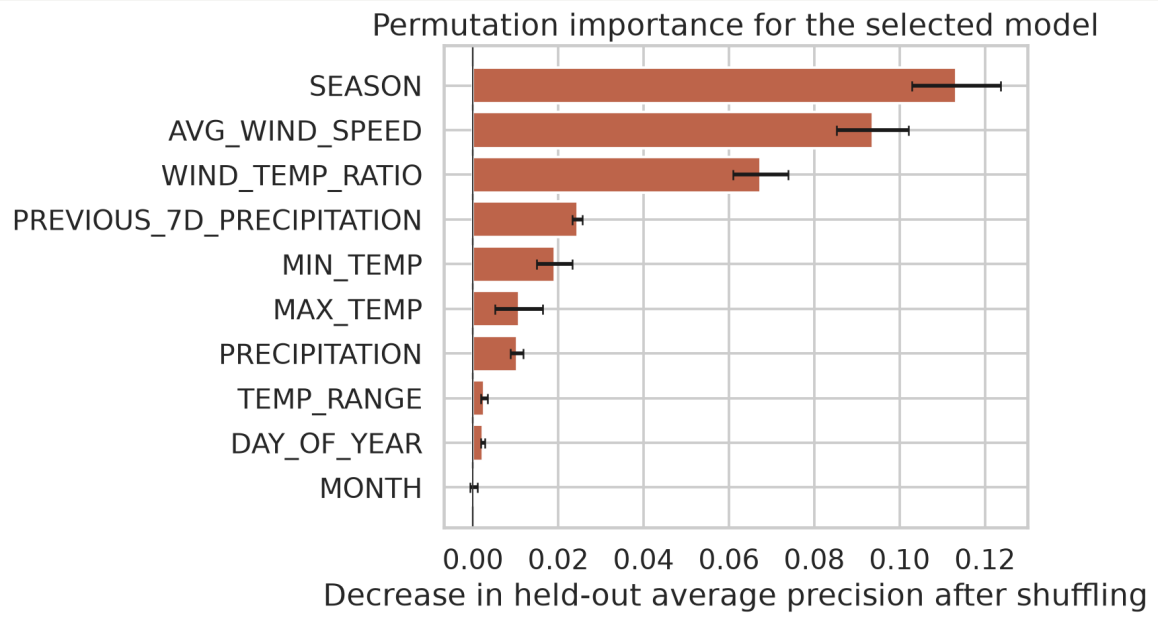
مصفوفة الالتباس: العدد

	تنبؤ: لا حريق	تنبؤ: حريق
فعلي: لا حريق	925	653
فعلي: حريق	175	**1,169**

استدعاء مرتفع للحريق مع عدد كبير من الإنذارات الإيجابية الكاذبة؛ العتبة 0.5 افتراضية وليست محسّنة لتكلفة تشغيلية.

كيف نفسر النتيجة؟

مقياس permutation importance: مقدار تراجع Average Precision عند خلط قيم المتغير



الموسم كان أكثر المتغيرات إسهامًا في ترتيب الحالات داخل الاختبار.

سرعة الرياح ونسبة الرياح إلى الحرارة تليان الموسم ضمن هذا النموذج والعينة.

التفسير وصفي لا سببي. لا يعني ترتيب الخصائص أن متغيرًا منفردًا يسبب الحريق.

درجات النموذج ليست احتمالات مخاطر معايرة، وعتبة 0.5 قابلة للنقاش حسب تكلفة تفويت الحريق مقابل الإنذار الخاطئ.

تنبيه: هذا الرسم تشخيص استكشافي لاحق للاختيار على عينة الاختبار؛ لا نستخدمه لإعادة تعديل النموذج والإبلاغ عن الاختبار نفسه كأنه تقييم مستقل جديد.

التحديات والخطوات قبل Demo Day

ما الذي يحدّ من النتيجة؟

- الفترة 2024–2025 كانت كلها موسومة False؛ استُبعدت بسبب احتمال نقص التغطية، وليس بدليل قاطع على سبب المشكلة.
- ارتفع معدل الحالات الموجبة من 31.0% في التدريب إلى 46.0% في الاختبار، ما يشير إلى تحول في توزيع البيانات.
- ميزات الطقس تشمل قياسات اليوم نفسه؛ لذلك لا تثبت النتائج قدرة الإنذار المسبق.
- التحقق الزمني لخمس طيات استُخدم لاختيار النموذج، ودرجة الفائز CV قد تكون متفائلة.

ما الذي نطوره لاحقًا؟

- تثبيت أفق تنبؤ مستقبلي واضح، مثل توقع بدء حريق في اليوم التالي، مع الاقتصار على معلومات متاحة قبل الأفق.
- التحقق من مصادر الوسوم وتحديث تغطية السنوات الأخيرة، وإضافة بيانات مكانية ومؤشرات الوقود والجفاف.
- ضبط العتبة على تحقق زمني داخل التدريب وفق تكلفة الإنذارات الخاطئة والحالات الفائتة، ثم معايرة الدرجات عند الحاجة.
- اختبار خارجي مستقل أو تقييم حسب المنطقة/الفترة قبل أي استخدام عملي.

الخلاصة: وسّعنا قاعدة البيانات، بنينا مقارنة زمنية عادلة، ووثقنا حدود النتائج قبل تحويلها إلى ادعاء تنبؤ تشغيلي.

تصنيف الحرائق القائم على البيانات

نجحنا في توسيع نطاق المشروع من عينة تجريبية بسيطة إلى تحليل يومي شامل لأكثر من 14,000 سجل. عبر تطبيق تقسيم زمني صارم وتصحيح الميزات، أسسنا خط أساس عالي الحساسية (استدعاء 87%) باستخدام نموذج الانحدار اللوجستي.

يقدم هذا المشروع حجر الأساس لنهج قائم على الأدلة لرصد الحرائق، مع تحديد الموسم والرياح كمؤشرات حرجة لليوم نفسه، ووضع ضوابط منهجية واضحة لأي أنظمة تنبؤ مستقبلية.

الأسئلة والنقاش

شكرًا لكم على وقتكم وحسن استماعكم.

مشروع تحليل حرائق الغابات • Demo Day 2026